

**LAPORAN TEKNIS ANALISIS DATA: SISTEM
REKOMENDASI *SKILL* BERBASIS DEEP LEARNING
UNTUK MENDUKUNG KEBUTUHAN KOMPETENSI**



Disusun oleh:

Muhammad Rizky Ramadhan	CDCC200D6Y2733
Haba L Herlambang Banjarnahor	CDCC180D6Y0738

CC26-PSU129

CODING CAMP POWERED BY DBS FOUNDATION

2026

DAFTAR ISI

BAB I PROBLEM DISCOVERY & PENDAHULUAN	3
1.1. Latar Belakang	3
1.2. Solusi Utama.....	3
1.3. Pertanyaan Bisnis.....	4
1.4. Batasan Proyek.....	6
BAB II DATA WRANGLING & PERSIAPAN DATA.....	8
2.1. Data Gathering	8
2.2. Data Assessing	8
2.3. Data Cleaning.....	10
2.4. Data Dictionary	12
BAB III EXPLORATORY DATA ANALYSIS (EDA) & EXPLANATORY ANALYSIS.....	13
3.1. EDA Dataset	13
3.2. Explanatory Data Analysis	14
BAB IV MEMBANGUN DATASET FINAL	20
4.1. <i>Feature Engineering</i> Untuk Dataset Final	20
4.2. Implementasi <i>A/B Testing</i>	22
4.3. <i>Feature Engineering</i> dan Pembangunan Dataset Final	23
BAB V PENGEMBANGAN <i>DASHBOARD</i> BERBASIS STREAMLIT	25
5.1. <i>Dashboard</i> Analisis Pasar Kerja IT	25
5.2. <i>Dashboard</i> Untuk Rekomendasi <i>Skill</i>	26
5.3. <i>Deploy Dashboard</i> Via Streamlit.....	27
BAB VI KESIMPULAN DAN REKOMENDASI	29
6.1. Kesimpulan	29
6.2. Rekomendasi.....	30
LAMPIRAN.....	31

BAB I

PROBLEM DISCOVERY & PENDAHULUAN

1.1. Latar Belakang

Perkembangan teknologi digital, khususnya dalam bidang *Artificial Intelligence* (AI) dan *Big Data*, telah mengubah lanskap dunia kerja secara signifikan. Transformasi ini menuntut tenaga kerja untuk memiliki keterampilan yang relevan, adaptif, dan sesuai dengan kebutuhan industri yang terus berkembang. Banyak pekerjaan lama mulai tergantikan oleh otomatisasi, sementara pekerjaan baru bermunculan dengan kebutuhan *skill* yang berbeda.

Namun, terdapat kesenjangan (*skill gap*) antara kompetensi yang dimiliki oleh pencari kerja dengan kebutuhan industri. Banyak individu kesulitan menentukan *skill* apa yang harus dipelajari agar tetap relevan di masa depan. Di sisi lain, informasi lowongan kerja yang tersedia sangat banyak, namun belum dimanfaatkan secara optimal untuk memberikan *insight* terkait tren kebutuhan *skill*.

Saat ini, sistem rekomendasi masih banyak digunakan pada *platform e-commerce* atau hiburan, tetapi belum dimaksimalkan untuk membantu pengembangan karier berbasis data pasar kerja. Dengan memanfaatkan metode *deep learning*, data lowongan kerja dapat dianalisis untuk mengidentifikasi pola kebutuhan *skill* serta memberikan rekomendasi yang lebih akurat dan personal. Oleh karena itu, diperlukan sebuah sistem yang mampu:

- Menganalisis tren lowongan kerja secara otomatis
- Mengidentifikasi *skill* yang sedang dan akan dibutuhkan
- Memberikan rekomendasi *skill* yang relevan bagi pengguna

Sistem ini diharapkan dapat membantu individu dalam merencanakan pengembangan kompetensi secara lebih terarah dan berbasis data.

1.2. Solusi Utama

Berdasarkan permasalahan pada latar belakang di atas, solusi utama yang akan dikembangkan adalah membangun sistem rekomendasi *skill* berbasis *deep learning*

yang memanfaatkan data lowongan kerja IT dari LinkedIn secara *global*. Sistem ini terdiri dari tiga komponen utama:

1. *Pipeline data*

Scraping, cleaning, dan transformasi data lowongan menjadi dataset terstruktur yang siap dianalisis dan dilatih

2. Model BiLSTM + Attention

Model deep learning yang mempelajari hubungan antara nama pekerjaan dan *skill* yang dibutuhkan, kemudian memberikan rekomendasi *skill* yang relevan

3. *Dashboard* interaktif

Antarmuka berbasis Streamlit yang memungkinkan pengguna memasukkan nama pekerjaan dan mendapatkan rekomendasi *skill* beserta career *roadmap* yang dihasilkan oleh model generatif Groq/LLaMA

Pendekatan ini dipilih karena kemampuannya untuk menangkap pola kompleks dari ribuan lowongan kerja nyata, bukan hanya mengandalkan daftar *skill* yang dikurasi secara manual.

1.3. Pertanyaan Bisnis

Berdasarkan latar belakang dan juga dataset yang telah diperoleh, dapat dibuat 6 pertanyaan bisnis yang relevan dengan adanya proyek ini, lebih jelasnya sebagai berikut:

1. BQ 1: Apa 30 *skill* yang paling banyak diminta berdasarkan dataset lowongan IT LinkedIn yang dikumpulkan?

Specific: Berfokus pada frekuensi kemunculan *skill* teknis di seluruh lowongan IT dalam dataset

Measurable: Diukur menggunakan jumlah kemunculan setiap *skill* token dan persentasenya terhadap total lowongan

Achievable: Dapat dijawab langsung dari kolom *Skills_list* yang telah dibangun pada tahap cleaning

Relevant: Menjawab kebutuhan pengguna sistem maupun pencari kerja dalam mengetahui *skill* apa yang harus diprioritaskan agar kompetitif di pasar kerja IT global

Time-bound: Dibatasi pada dataset yang dikumpulkan (April – Juni 2026)

2. BQ 2: Bagaimana persentase distribusi *work type* (*Remote*, *Hybrid*, *On-site*) pada 20 kategori pekerjaan IT dengan volume lowongan tertinggi berdasarkan dataset yang dikumpulkan?

Specific: Berfokus pada pola sebaran tipe kerja per kategori pekerjaan, dibatasi pada 20 kategori dengan volume tertinggi

Measurable: Diukur menggunakan persentase proporsi masing-masing *work type* per kategori pekerjaan

Achievable: Dapat dijawab dari kolom *work_type* dan *keyword* yang tersedia di dataset

Relevant: Membantu pencari kerja yang memiliki preferensi kerja *remote* atau *on-site* dalam memilih jalur karier yang sesuai dengan gaya hidup mereka

Time-bound: Dibatasi pada dataset yang dikumpulkan (April – Juni 2026)

3. BQ 3: Kategori pekerjaan IT mana yang memiliki rata-rata jumlah *skill* tertinggi per lowongan berdasarkan dataset yang dikumpulkan?

Specific: Berfokus pada perbandingan kompleksitas *skill* antar kategori pekerjaan IT

Measurable: Diukur menggunakan rata-rata kolom *n_Skills* per kategori pekerjaan

Achievable: Dapat dijawab langsung dari kolom *n_Skills* dan *keyword* yang tersedia

Relevant: Membantu pencari kerja memperkirakan seberapa besar investasi waktu dan energi yang dibutuhkan sebelum melamar ke jalur karier tertentu

Time-bound: Dibatasi pada dataset yang dikumpulkan (April – Juni 2026)

4. BQ 4: *Skill* apa yang memiliki distinctiveness ratio tertinggi pada masing-masing kategori pekerjaan IT berdasarkan dataset yang dikumpulkan?

Specific: Berfokus pada *skill* yang paling eksklusif dan membedakan satu kategori pekerjaan dari kategori lainnya

Measurable: Diukur menggunakan distinctiveness ratio, yaitu perbandingan antara tingkat kemunculan *skill* di pekerjaan tertentu dengan tingkat kemunculannya secara global

Achievable: Dapat dihitung dari kolom *Skills_list* dan *keyword* yang tersedia di dataset

Relevant: Membantu pencari kerja untuk fokus mempelajari *skill* yang benar-benar membedakan mereka di posisi yang dituju, bukan hanya *skill* generik yang semua orang miliki

Time-bound: Dibatasi pada dataset yang dikumpulkan (April – Juni 2026)

5. BQ 5: Apakah rata-rata jumlah *skill* lowongan *Remote* secara statistik lebih tinggi dibanding *On-site* berdasarkan dataset yang dikumpulkan?

Specific: Berfokus pada perbandingan tuntutan *skill* antara dua tipe kerja yang paling umum, yaitu *Remote* dan *On-site*

Measurable: Diukur menggunakan rata-rata *n_Skills* per tipe kerja dan divalidasi melalui independent samples t-test dengan $\alpha = 0.05$

Achievable: Dapat dijawab dari kolom *n_Skills* dan *work_type* yang tersedia di dataset

Relevant: Membantu pencari kerja yang ingin bekerja secara *remote* untuk memahami bahwa mereka perlu mempersiapkan *skill* yang lebih banyak dan lebih spesifik dibanding posisi *on-site*

Time-bound: Dibatasi pada dataset yang dikumpulkan (April – Juni 2026)

6. BQ 6: Apa 20 pasangan *skill* dengan nilai *co-occurrence* tertinggi berdasarkan dataset lowongan IT LinkedIn yang dikumpulkan?

Specific: Berfokus pada pola kemunculan bersama antar *skill* dalam satu lowongan, dibatasi pada 20 pasangan teratas

Measurable: Diukur menggunakan nilai *co-occurrence*, yaitu jumlah lowongan di mana dua *skill* muncul secara bersamaan

Achievable: Dapat dihitung dari kolom *Skills_list* menggunakan pendekatan combinatorial pair counting

Relevant: Membantu pencari kerja menyusun *roadmap* belajar yang efisien dengan mempelajari *skill* dalam satu klaster secara berurutan, bukan secara acak

Time-bound: Dibatasi pada dataset yang dikumpulkan (April – Juni 2026)

1.4. Batasan Proyek

Proyek ini memiliki keterbatasan karena cakupan prediksinya yang hanya difokuskan pada ranah teknologi informasi, sehingga model yang dikembangkan belum

mampu menangani kompleksitas maupun karakteristik unik dari bidang pekerjaan di luar sektor tersebut.

BAB II

DATA WRANGLING & PERSIAPAN DATA

2.1. Data Gathering

Data yang digunakan dalam proyek ini bersumber dari hasil scraping yang dilakukan terhadap web LinkedIn. Data yang terkumpul sendiri berjumlah 4542 data yang masih mentah dan masih belum dilakukan proses pembersihan apapun. Dataset mentah ini sendiri memiliki 7 fitur yang lebih detailnya dijelaskan di tabel di bawah ini:

Fitur	Deskripsi
<i>keyword</i>	<i>Keyword</i> yang digunakan dalam mencari data lowongan kerja
<i>job_title</i>	Nama lowongan kerja yang ditemukan
<i>company</i>	Nama perusahaan yang memberikan lowongan kerja
<i>location</i>	Lokasi pekerjaan
<i>work-type</i>	Tipe pekerjaan (<i>Remote/On-site/Hybrid</i>)
<i>salary</i>	Gaji untuk lowongan pekerjaan
<i>Skills</i>	<i>Skills</i> yang dibutuhkan
<i>description</i>	Deskripsi lowongan pekerjaan

Berikut ini adalah gambaran dataset mentah yang didapatkan dari scraping web LinkedIn.

keyword	job_title	company	location	work_type	salary	skills	job_url	description
"Back End Dev	Back-end Developer	Keyvoto	Yunani (Jarak Jauh)			C, C#, CSS3, HTML	https://www.keyvoto.com	Keyvoto Back-end
"Back End Dev	Java Back-End Developer	Müller's Solutions	Riyadh, Riyadh, Arab Saudi (Di Kantor)			Docker, Git, GitLab	https://www.muellersolutions.com	Müller's Solutions
"Back End Dev	Back End Developer	RXPART ADVISORS	Delhi, India (Di Kantor)			C, C++, Foundation	https://www.rxpertadvisors.com	RXPART ADVISORS
"Back End Dev	Back End Developer w	Digital Waffle	Spanyol (Jarak Jauh)			Docker, Git, GitLab	https://www.digitalwaffle.com	Digital Waffle Back
"Back End Dev	Junior Back-End Developer	Analyticsmart	Toronto, ON (Di Kantor)			Angular, Computer	https://www.analyticsmart.com	Analyticsmart Junior
"Back End Dev	Back End Developer	Orbis Group	Britania Raya (Jarak Jauh)			DynamoDB, NoSQL	https://www.orbisgroup.com	Orbis Group Back
"Back End Dev	Back End Developer	Precise Resource	Area Metropolitan Columbus, Ohio (Di Kantor)			Amazon Web Services	https://www.preciseresource.com	Precise Resource

2.2. Data Assessing

Pada bagian ini, akan dilakukan pemeriksaan awal terhadap kualitas struktur data mentah, yang mencakup beberapa hal seperti jumlah baris, missing *value*, data duplikat, tipe data, dan sebagainya. Lebih jelasnya sebagai berikut:

1. Jumlah baris dan kolom

Dataset mentah ini terisi dari 4542 baris dan 9 kolom atau fitur, dengan tiap baris merepresentasikan data satu lowongan pekerjaan.

Jumlah baris : 4,542

Jumlah kolom : 9

Nama kolom : ['keyword', 'job_title', 'company', 'location', 'work_type', 'salary', 'skills', 'job_url', 'description']

2. Missing value

Dataset mentah ini memiliki missing *value* penuh pada fitur *work-type* dan *salary* serta beberapa missing *value* pada fitur *Skills*, *company* dan *description*. Akan tetapi missing *value* pada fitur *work-type* bisa di isi melalui pengekstrakan pada fitur *location*. Kemudian kita hanya akan membuang fitur *salary* karena sepenuhnya kosong, untuk missing *value* pada fitur lainnya tidak akan di buang karena jika di buang, maka bisa jadi ada informasi lain yang berharga untuk proses EDA yang terbangun.

```
Missing Values per Kolom:
      Count  Pct (%)
company      6    0.13
work_type  4542  100.00
salary      4542  100.00
skills       594   13.08
description   5    0.11
```

3. Data duplikat

Dataset mentah ini memiliki duplikat pada fitur URL serta pada *value* fitur *job_title*, *Skills* dan *company* yang sama, hal ini terjadi karena jika nilai pada fitur *job_title*, *Skills* dan *company* tersebut antara data 1 dan data 2 sama, maka jelas data tersebut merupakan data lowongan kerja yang dipublikasikan berkali-kali.

```
Duplikat baris penuh      : 0
Duplikat URL              : 8
Duplikat title + skill + co. : 548
```

4. Tipe data

Tipe data dari dataset ini belum sepenuhnya sesuai dengan tipe data yang seharusnya, di mana fitur *work-type* seharusnya bertipe data *object* bukan *float64*.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4542 entries, 0 to 4541
Data columns (total 9 columns):
#   Column      Non-Null Count  Dtype
---  -
0   keyword     4542 non-null   object
1   job_title   4542 non-null   object
2   company     4536 non-null   object
3   location    4542 non-null   object
4   work_type   0 non-null      float64
5   salary      0 non-null      float64
6   skills      3948 non-null   object
7   job_url     4542 non-null   object
8   description 4537 non-null   object
dtypes: float64(2), object(7)
```

5. *Inconsistent formatting*

Inconsistent formatting terjadi pada fitur *keyword*, dimana ada tanda kutip ganda untuk *value* di dalam fitur tersebut.

keyword

"Back End Developer"

"Back End Developer"

6. Fitur *Skills* Berformat String, Bukan List

Fitur *Skills* menyimpan data dalam format string tunggal seperti Python, SQL, Docker. Format ini tidak dapat langsung digunakan untuk analisis frekuensi maupun *co-occurrence*, sehingga perlu diurai menjadi list.

2.3. Data Cleaning

Pada bagian ini akan dilakukan cleaning data untuk menangani masalah kualitas data pada poin 2.2, lebih detailnya sebagai berikut:

1. Menangani *Inconsistent Formatting* (Fitur *keyword*)

Dilakukan pembersihan pada kolom *keyword* dengan menghapus tanda kutip ganda dan spasi berlebih agar format data menjadi konsisten dan seragam. Sepotong kode di bawah ini digunakan untuk melakukan hal tersebut.

```
df_eda['keyword'] = df_eda['keyword'].str.replace('"', '').str.strip()
```

2. Menangani *Missing Value* pada Fitur *work-type*

Missing value pada fitur *work-type* ditangani dengan mengekstrak informasi dari kolom location seperti “Jarak Jauh”, “Di Kantor”, dan “Gabungan” yang selanjutnya dipetakan ke kolom *work-type* dengan aturan seperti berikut:

- Jarak Jauh → *Remote*
- Di Kantor → *On-site*
- Gabungan → *Hybrid*

```
def extract_work_type(loc):  
    if not isinstance(loc, str): return 'Tidak Diketahui'  
    if 'Jarak Jauh' in loc: return 'Remote'  
    if 'Di Kantor' in loc: return 'On-site'  
    if 'Gabungan' in loc: return 'Hybrid'  
    return 'Tidak Diketahui'
```

```
df_eda['work_type'] = df_eda['location'].apply(extract_work_type)
```

3. *Missing Value* dan *Feature Engineering* Dataset untuk EDA

Kolom *Skills* dipecah berdasarkan pemisah koma, lalu setiap *skill* diubah ke huruf kecil dan dibersihkan dari spasi. *Skill* dengan panjang kurang dari 2 karakter dibuang karena dianggap tidak merepresentasikan nama *skill* yang valid. Hasilnya disimpan di kolom baru *Skills_list*, dan dari kolom tersebut diturunkan kolom *n_Skills* yang berisi jumlah *skill* per baris.

```
df_eda['skills_list'] = df_eda['skills'].apply(
    lambda x: [s.strip().lower() for s in str(x).split(',') if s.strip() and len(s.strip()) > 1]
    if pd.notna(x) else []
)
df_eda['n_skills'] = df_eda['skills_list'].apply(len)
```

4. Ekstraksi *location_fix* dari fitur location

Dibuat fungsi *extract_location* yang terlebih dahulu membersihkan bagian dalam kurung seperti (Jarak Jauh), kemudian mengambil elemen terakhir setelah pemisah koma sebagai nama lokasi.

```
def extract_location(loc):
    if not isinstance(loc, str): return 'Unknown'
    clean = re.sub(r'\(.*?\)', '', loc).strip()
    parts = [p.strip() for p in clean.split(',')]
    return parts[-1].strip() if parts else 'Unknown'
```

```
df_eda['location_fix'] = df_eda['location'].apply(extract_location)
```

5. Menghapus baris duplikat

Baris duplikat dihapus berdasarkan kombinasi fitur *job_title*, *Skills*, dan *company* dengan mempertahankan kemunculan pertama. Kolom *salary* tidak ditangani lebih lanjut karena seluruh nilainya kosong dan tidak ada fitur dalam dataset yang memang memuat informasi terkait *salary*.

```
df_eda = df_eda.drop_duplicates(subset=['job_title', 'skills', 'company'], keep='first')
```

6. Drop fitur *salary*

Fitur *salary* yang sepenuhnya kosong akan di buang karena tidak memberikan informasi apapun

```
df_eda = df_eda.drop(columns=['salary'])
```

Setelah dilakukan pembersihan, diperoleh dataset yang siap digunakan untuk melakukan analisis sesuai dengan pertanyaan bisnis seperti berikut

keyword	job_title	company	location	work_type	skills	job_url	description	location_fix	skills_list	n_skills
Back End Developer	Back-end Developer	Keyvoto	Yunani (Jarak Jauh)	Remote	C, C#, CSS3, HTML5, Python, SQL	https://www.linkedin.com/jobs/view/4412722324/	Keyvoto Back-end Developer Yunani - 2 minggu y...	Yunani	[c#, css3, html5, python, sql]	5
Back End Developer	Java Back-End Developer with Banking Experience	Müller's Solutions	Riyadh, Riyadh, Arab Saudi (Di Kantor)	On-site	Docker, Git, GitLab, Hibernate, Java, Jenkins,...	https://www.linkedin.com/jobs/view/4419444263/	Müller's Solutions Java Back-End Developer wit...	Arab Saudi	[docker, git, gitlab, hibernate, java, jenkins...]	13

Dengan masing-masing tipe data fiturnya seperti berikut ini:

```
<class 'pandas.core.frame.DataFrame'>
Index: 3994 entries, 0 to 4540
Data columns (total 11 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   keyword                3994 non-null   object
1   job_title              3994 non-null   object
2   company                3990 non-null   object
3   location               3994 non-null   object
4   work_type              3994 non-null   object
5   skills                 3477 non-null   object
6   job_url                3994 non-null   object
7   description            3989 non-null   object
8   location_fix           3994 non-null   object
9   skills_list            3994 non-null   object
10  n_skills               3994 non-null   int64
```

2.4. Data Dictionary

Selanjutnya dari dataset baru (df_eda) yang telah diperoleh, bisa dibuat *data dictionary* seperti di bawah ini:

	Kolom	Tipe	Deskripsi	Contoh Nilai	Catatan
0	keyword	string	Kata kunci jabatan yang digunakan saat scraping LinkedIn	Data Scientist, Back End Developer	105 nilai unik
1	job_title	string	Judul pekerjaan asli dari posting LinkedIn	Senior Data Scientist at Google	sangat beragam
2	company	string	Nama perusahaan pemasang lowongan	Google, Tokopedia	beberapa null
3	location	string	Lokasi dan tipe kerja dalam satu kolom	Jakarta, Indonesia (Jarak Jauh)	
4	work_type	string	Tipe kerja hasil ekstraksi dari kolom location	Remote / On-site / Hybrid	hasil cleaning
5	location_fix	string	Negara hasil ekstraksi dari kolom location	Indonesia, India, United Kingdom	hasil cleaning
6	skills_list	list[string]	Skill teknis hasil parsing dari kolom skills	['python', 'sql', 'docker']	hasil cleaning
7	n_skills	integer	Jumlah skill yang tercantum per lowongan	7	hasil cleaning
8	skills	string	Skill teknis dalam format string asli	Python, SQL, Docker	kolom asli
9	job_url	string	URL posting lowongan di LinkedIn	https://linkedin.com/...	unique identifier

BAB III


EXPLORATORY DATA ANALYSIS (EDA) & EXPLANATORY ANALYSIS

Setelah data berhasil dibersihkan dan pembuatan kolom baru selesai, tahap selanjutnya adalah *Exploratory Data Analysis* (EDA). Tujuan EDA pada proyek ini bukan sekadar memahami struktur data, melainkan untuk menggali pola dan *insight* dari pasar kerja IT global yang nantinya akan menjawab enam pertanyaan bisnis yang telah dirumuskan. Dataset yang digunakan pada tahap ini adalah `df_eda` yang diperoleh dari hasil proses data *wrangling* sebelumnya, dengan total lowongan yang telah bersih dari duplikat.

EDA diawali dari gambaran umum dataset melalui empat visualisasi ringkasan, kemudian dilanjutkan secara berurutan menjawab BQ 1 hingga BQ 6. Setiap BQ dirancang untuk menjawab satu dimensi spesifik dari pasar kerja IT, mulai dari *skill* yang paling diminati, pola *work type*, kompleksitas *skill* per pekerjaan, *skill* yang menjadi ciri dari pekerjaan tertentu, perbedaan tuntutan *skill* antara *remote* dan *on-site*, hingga kombinasi *skill* yang paling sering muncul bersama.

3.1. EDA Dataset

Sebelum masuk ke pertanyaan bisnis spesifik, dilakukan eksplorasi umum untuk memahami distribusi data secara keseluruhan. Akan disajikan eksplorasi umum untuk memahami distribusi data secara keseluruhan pada gambar di bawah ini:



Dari empat visualisasi yang dihasilkan, diperoleh gambaran awal sebagai berikut:


1. Dari sisi distribusi *work type*, mayoritas lowongan dalam dataset bersifat *On-site*, diikuti *Remote*, kemudian *Hybrid*. Ini menunjukkan bahwa meskipun tren *remote* semakin populer, lowongan konvensional masih mendominasi pasar kerja IT secara global.
2. Dari sisi sebaran lokasi, dataset didominasi oleh lowongan dari lokasi berbahasa Inggris dan Asia Selatan seperti India, Amerika Serikat, dan Inggris. Ini perlu dicatat sebagai batasan karena *insight* yang dihasilkan lebih merepresentasikan pasar kerja IT di lokasi-lokasi tersebut dibanding pasar lokal Indonesia.
3. Dari sisi distribusi jumlah *skill* per lowongan, distribusinya cenderung *right-skewed* dengan nilai mean lebih tinggi dari median. Artinya sebagian besar lowongan mencantumkan *skill* dalam jumlah sedang, namun ada sejumlah kecil lowongan yang mencantumkan *skill* dalam jumlah sangat banyak sehingga menarik rata-rata ke atas.
4. Dari sisi volume per *keyword*, tidak semua dari 105 *keyword* memiliki volume lowongan yang seimbang. Beberapa *keyword* seperti *Data Scientist* dan *Software Engineer* mendominasi, sementara *keyword* yang lebih spesifik seperti *MLOps Engineer* atau *Flutter Developer* memiliki volume jauh lebih kecil. Ketimpangan ini perlu diperhatikan saat menginterpretasikan hasil analisis per kategori pekerjaan, karena kategori dengan volume kecil memiliki representasi statistik yang lebih lemah.

3.2. Explanatory Data Analysis

Setelah tahap EDA memberikan gambaran umum tentang karakteristik dataset, langkah selanjutnya adalah melakukan Explanatory Data Analysis. Berbeda dengan EDA yang bersifat eksploratif, pada tahap ini analisis dilakukan secara lebih terarah dengan tujuan menjawab setiap pertanyaan bisnis yang telah dirumuskan sebelumnya. Jawaban untuk *business question* yang sebelumnya telah di rumuskan akan dijawab di bawah ini.

1. Apa 30 *skill* yang paling banyak diminta berdasarkan dataset lowongan IT LinkedIn Global?

Jawaban dari pertanyaan diatas dapat dilihat pada gambar ini:




Berdasarkan hasil visualisasi di atas, Python mendominasi pasar dengan kemunculan sekitar 25% dari seluruh dataset. *Skill* ini bukan lagi sekadar keunggulan kompetitif, melainkan sudah menjadi prasyarat dasar di hampir seluruh kategori pekerjaan IT.

Kemudian berdasarkan visualisasi di atas, terlihat lima *skill* teratas mencerminkan dua klaster besar: klaster data *pipeline* (Python, SQL) dan klaster *cloud infrastructure* (Kubernetes, Docker, Terraform). Pola ini menunjukkan bahwa industri IT global saat ini sangat berorientasi pada kemampuan mengelola data dan infrastruktur *cloud* secara bersamaan, bukan hanya kemampuan *coding* dasar. Git yang masuk di posisi atas sudah menjadi *hygiene factor* hampir selalu disyaratkan tanpa memandang kategori pekerjaan.

2. Bagaimana persentase distribusi *work type* (*Remote*, *Hybrid*, *On-site*) pada 20 kategori pekerjaan IT dengan volume lowongan tertinggi berdasarkan dataset yang dikumpulkan?

Jawaban dari pertanyaan diatas dapat dilihat pada gambar ini:




Berdasarkan gambar di atas, pola distribusi tipe kerja sangat berbeda-beda antar kategori pekerjaan dan sejalan dengan sifat pekerjaan masing-masing.

Pekerjaan yang sepenuhnya dilakukan via terminal dan *Dashboard* cloud seperti *DevOps Engineer* dan *Cloud Engineer* memiliki persentase *remote* tertinggi. Sebaliknya, pekerjaan IT Ops, *Network Engineer*, dan *IT Support* yang memerlukan akses fisik ke perangkat keras atau koordinasi tatap muka dengan pengguna non-teknis tetap didominasi oleh tipe *on-site*. Informasi ini penting bagi pencari kerja yang memprioritaskan fleksibilitas lokasi kerja dalam memilih jalur karier.

- Kategori pekerjaan IT mana yang memiliki rata-rata jumlah *skill* tertinggi per lowongan berdasarkan dataset yang dikumpulkan?


Jawaban dari pertanyaan diatas dapat dilihat pada gambar ini:



Berdasarkan gambar di atas, jenis pekerjaan DevOps/Cloud secara konsisten berada di puncak dengan rata-rata 7 sampai 8 *skill* per lowongan. Hal ini mencerminkan bahwa peran ini menyentuh banyak *layer* teknologi sekaligus, mulai dari sistem operasi, *container orchestration*, *CI/CD pipeline*, *monitoring*, hingga *cloud provider*. Pencari kerja bisa menggunakan *insight* ini untuk memperkirakan lebar persiapan yang dibutuhkan sebelum melamar ke jalur karier tertentu.


4. *Skill* apa yang memiliki distinctiveness ratio tertinggi pada masing-masing kategori pekerjaan IT berdasarkan dataset yang dikumpulkan?

Jawaban dari pertanyaan diatas dapat dilihat pada gambar ini:



Berdasarkan gambar diatas, setiap kategori pekerjaan karakteristik *skill* yang sangat khas dan mudah dikenali. *Flutter Developer* hampir eksklusif membutuhkan Dart dan Flutter dengan rasio 50 sampai 68 kali di atas rata-rata global. *Machine Learning Engineer* sangat identik dengan PyTorch dan framework ML lainnya. *Cyber Security Analyst* memiliki SIEM dan Incident Response sebagai *skill* pembeda utama. Pola ini konsisten dan dapat diandalkan sebagai panduan bagi pencari kerja untuk mengidentifikasi *skill* yang benar-benar membedakan mereka di kategori pekerjaan yang dituju, bukan hanya *skill* umum yang dimiliki semua orang.


5. Apakah rata-rata jumlah *skill* lowongan *Remote* secara statistik lebih tinggi dibanding *On-site* berdasarkan dataset yang dikumpulkan?



Berdasarkan gambar diatas, terlihat bahwa lowongan *remote* rata-rata mencantumkan sekitar 43% lebih banyak *skill* dibanding lowongan *on-site*. Pola ini konsisten dan bukan kebetulan. Perusahaan yang membuka posisi *remote* cenderung mencari kandidat yang lebih self-sufficient secara teknis karena tidak ada supervisi atau mentoring langsung di tempat kerja. Kandidat diharapkan mampu mengoperasikan, men-debug, dan memelihara sistem secara mandiri. *Skill* berbasis infrastruktur otomatis seperti Kubernetes dan Terraform secara proporsional jauh lebih sering muncul di lowongan *remote* dibanding *on-site*, karena tools inilah yang memungkinkan pengelolaan sistem dari jarak jauh.

6. Apa 20 pasangan *skill* dengan nilai *co-occurrence* tertinggi berdasarkan dataset lowongan IT LinkedIn yang dikumpulkan?

Jawaban dari pertanyaan diatas dapat dilihat pada gambar ini:



Berdasarkan gambar diatas, terlihat bahwa Python + SQL adalah pasangan *skill* paling dominan, muncul bersama di ratusan lowongan. Ini mengkonfirmasi bahwa kemampuan scripting dan kemampuan query data adalah fondasi yang hampir selalu dipadukan oleh industri.

Dari *co-occurrence matrix* terlihat dua klaster *skill* yang sangat kohesif:

- Klaster Data: Python, SQL, dan *Machine Learning* saling terkait erat
- Klaster DevOps: Docker, Kubernetes, dan Terraform hampir selalu muncul bersama

Pencari kerja sebaiknya mempelajari *skill* dalam satu klaster secara berurutan, bukan secara acak lintas klaster. Pola ini bisa dijadikan panduan *roadmap* belajar yang lebih terarah dan sejalan dengan ekspektasi industri nyata.

BAB IV

MEMBANGUN DATASET FINAL

Pada tahap ini, tujuan utamanya adalah membangun `df_final` sebagai dataset yang benar-benar siap digunakan sebagai data latih oleh tim *AI Engineer*.

4.1. *Feature Engineering Untuk Dataset Final*

Setelah proses EDA selesai, dataset `df_eda` belum sepenuhnya siap digunakan sebagai data latih model. Permasalahan utama yang perlu diselesaikan adalah kolom `job_title` yang sangat tidak terstruktur dimana satu posisi pekerjaan yang sama bisa ditulis dalam puluhan variasi berbeda di LinkedIn. Sebagai contoh, posisi Data Scientist saja bisa muncul sebagai *Senior Data Scientist at Google*, *Data Scientist (Remote)*, *Sr. Data Scientist*, *Lead Data Scientist - APAC*, dan sebagainya. Jika langsung digunakan tanpa normalisasi, model tidak akan mampu mengenali bahwa seluruh variasi tersebut sebenarnya merujuk pada satu kategori pekerjaan yang sama.

Untuk menyelesaikan permasalahan ini, dilakukan normalisasi label menggunakan pendekatan TF-IDF character *n-gram similarity* dengan langkah-langkah sebagai berikut:

1. Membangun referensi *keyword* standar

Seluruh 105 *keyword* unik dari kolom `'keyword'` diambil sebagai daftar kategori pekerjaan standar yang menjadi acuan pemetaan. Daftar ini diurutkan secara alfabetis untuk memastikan konsistensi.

```
KEYWORDS = sorted(df_eda['keyword'].unique().tolist())
```

2. Melatih TF-IDF Vectorizer

TF-IDF vectorizer dilatih dengan parameter `analyzer=char_wb` dan `ngram_range = (2,4)`. Pendekatan character n-gram dipilih karena bekerja pada dalam skala karakter, bukan kata, sehingga lebih toleran terhadap typo, singkatan, dan variasi penulisan yang umum ditemukan pada judul pekerjaan di LinkedIn.

```
tfidf_vec = TfidfVectorizer(analyzer='char_wb', ngram_range=(2, 4))
```

3. Transformasi *keyword* ke ruang vektor

Seluruh 105 *keyword* standar ditransformasi ke dalam matriks vektor TF-IDF. Matriks ini menjadi ruang referensi yang akan digunakan untuk membandingkan setiap input.

```
keyword_matrix = tfidf_vec.fit_transform(KEYWORDS)
```

4. Pemetaan via cosine similarity

Setiap nilai job_title ditransformasi ke vektor TF-IDF yang sama, kemudian dihitung cosine similarity-nya terhadap seluruh 105 keyword. Keyword dengan skor tertinggi dipilih sebagai hasil pemetaan. Jika skor tertinggi masih di bawah threshold 0.15, input dikembalikan apa adanya tanpa dipaksa masuk ke kategori manapun ini untuk menghindari pemetaan yang salah pada judul pekerjaan yang benar-benar di luar cakupan dataset.

```
def map_to_keyword(user_input: str, threshold: float = 0.15) -> str:
    # Mengubah input ke vektor TF-IDF lalu mencari keyword terdekat via cosine similarity
    vec = tfidf_vec.transform([user_input.lower()])
    scores = cosine_similarity(vec, keyword_matrix).flatten()
    idx = int(np.argmax(scores))
    if scores[idx] >= threshold:
        return KEYWORDS[idx]
    return user_input
```

Setelah mengikuti tahapan di atas, dilakukan pengujian seperti berikut

```
tests = [
    ('backend dev', 'Back End Developer'),
    ('ML Osp', 'MLOps Engineer'),
    ('data sci', 'Data Scientist'),
    ('DevOps', 'DevOps Engineer'),
    ('frond end developer', 'Front End Developer'),
    ('flutter dev', 'Flutter Developer'),
    ('cyber security', 'Cyber Security Analyst'),
    ('mlops engineer', 'MLOps Engineer'),
]
print('Quick test mapping:')
for inp, expected in tests:
    result = map_to_keyword(inp)
    status = 'OK' if result == expected else f'expected: {expected}'
    print(f' {inp:30s} -> {result:35s} {status}')
```

Dan diperoleh hasil seperti berikut:

Keywords tersedia: 105 kategori

Quick test mapping:

backend dev	-> Back End Developer	OK
ML Osp	-> MLOps Engineer	OK
data sci	-> Data Scientist	OK
DevOps	-> DevOps Engineer	OK
frond end developer	-> Front End Developer	OK
flutter dev	-> Flutter Developer	OK
cyber security	-> Cyber Security Analyst	OK
mlops engineer	-> MLOps Engineer	OK

Dari hasil tersebut dapat diambil kesimpulan TF-IDF character n-gram dengan ngram_range = (2,4) terbukti efektif menangkap kesamaan antar variasi penulisan judul pekerjaan. Berdasarkan quick test yang dilakukan, seluruh

variasi input seperti backend dev, ML Osp, data sci, maupun frond end *developer* berhasil dipetakan ke *keyword* standar yang tepat. Threshold 0.15 memberikan toleransi yang cukup untuk menangani variasi penulisan yang umum sekaligus tetap menghindari pemetaan yang salah untuk input yang terlalu jauh dari *keyword* manapun.

4.2. Implementasi A/B Testing

Pada bagian BQ 5 sebelumnya, telah ditemukan secara deskriptif bahwa lowongan *Remote* rata-rata mencantumkan lebih banyak *skill* dibanding lowongan *On-site*. Namun temuan deskriptif saja belum cukup untuk dijadikan kesimpulan yang kuat, karena perbedaan rata-rata yang terlihat bisa saja terjadi secara kebetulan akibat variasi sampling, bukan karena perbedaan yang nyata di populasi sesungguhnya.

Oleh karena itu, dilakukan *A/B Testing* untuk memvalidasi temuan tersebut secara statistik. *A/B Testing* yang dilakukan bukan eksperimen intervensi seperti di dunia produk, melainkan pengujian hipotesis dua sampel independen, dimana grup A adalah seluruh lowongan *Remote* dan grup B adalah seluruh lowongan *On-site*.

Sebelum memilih jenis uji statistik yang digunakan, terlebih dahulu dilakukan Levene Test untuk memeriksa apakah variansi kedua grup homogen atau tidak. Hasil Levene Test menentukan apakah t-test yang dijalankan menggunakan asumsi equal variance atau Welch correction. Langkah ini penting karena mengabaikannya bisa menghasilkan nilai p yang tidak akurat.


Setelah asumsi variansi diketahui, dilakukan Independent Samples t-test satu arah dengan hipotesis sebagai berikut:

H_0 : Tidak ada perbedaan rata-rata jumlah *skill* antara lowongan *Remote* dan *On-site*

H_1 : Rata-rata jumlah *skill* lowongan *Remote* lebih tinggi dibanding *On-site*

Uji dipilih satu arah karena hipotesis alternatif sudah berarah. berdasarkan temuan deskriptif BQ 5 sebelumnya sudah ada indikasi bahwa *Remote* lebih tinggi, bukan sekadar berbeda. Tingkat signifikansi yang digunakan adalah $\alpha = 0.05$, yang berarti toleransi kesalahan tipe I sebesar 5%.

Hasil pengujian kemudian divisualisasikan dalam dua bentuk: *KDE plot overlay* untuk membandingkan bentuk distribusi kedua grup secara keseluruhan, dan boxplot berdampingan dengan anotasi nilai *p-value* untuk memperlihatkan perbedaan tendensi sentral secara langsung. Lebih jelasnya di bawah ini:



Uji statistik satu arah menghasilkan nilai p yang jauh di bawah ambang signifikansi $\alpha = 0.05$, sehingga H_0 ditolak. Terdapat bukti statistik yang kuat bahwa lowongan *Remote* secara rata-rata mensyaratkan jumlah *skill* yang lebih banyak dan signifikan dibandingkan lowongan *On-site*.

Temuan ini mengkonfirmasi hasil analisis deskriptif pada BQ 5 dan memberikan landasan statistik yang valid untuk kesimpulan bahwa perusahaan yang membuka posisi *remote* memang menuntut kandidat yang lebih self-sufficient secara teknis.

4.3. Feature Engineering dan Pembangunan Dataset Final

Setelah proses normalisasi label selesai dan fungsi mapper tervalidasi, tahap selanjutnya adalah membangun `df_final` sebagai dataset akhir. Berbeda dengan `df_eda` yang dibuat untuk keperluan eksplorasi dan analisis bisnis, `df_final` dirancang khusus agar dapat langsung digunakan langsung oleh tim *AI Engineer* tanpa perlu preprocessing tambahan.

Pada tahap ini terdapat dua proses utama yang dilakukan secara bersamaan saat membangun `df_final`. Lebih jelasnya sebagai berikut:

1. Normalisasi Label

Setiap nilai `job_title` dari `df_eda` yang masih dalam bentuk asli dari LinkedIn dipetakan ke salah satu dari 105 *keyword* standar menggunakan fungsi `map_to_keyword()` yang telah dibuat di bagian sebelumnya. Hasil pemetaan ini

disimpan di kolom baru bernama `job_mapped`, yang nantinya akan menjadi label target atau dengan kata lain, inilah yang akan diprediksi oleh model ketika menerima input berupa nama pekerjaan dari pengguna.

2. *Feature Engineering* pada Kolom *Skills*

Kolom `Skills_list` yang sebelumnya berbentuk list Python seperti `['python', 'sql', 'docker']` dikonversi menjadi string dengan separator koma menjadi `python, sql, docker`. Hal ini dilakukan karena format list Python tidak dapat ditulis langsung ke dalam file CSV karena akan menghasilkan representasi string yang ambigu saat dibaca kembali. Selain itu, tokenizer dan embedding layer yang akan digunakan di tahap modeling mengharapkan input berupa string teks yang bersih, bukan struktur data Python.

Di luar dua proses utama tersebut, ada satu langkah filtering yang juga dilakukan, yaitu membuang seluruh baris yang tidak memiliki *skill* sama sekali. Baris semacam ini tidak memiliki informasi output yang bisa dipelajari oleh model tidak ada pasangan input-output yang valid. Menyertakannya dalam data latih hanya akan menambah noise dan berpotensi mengganggu proses konvergensi model, sehingga lebih aman untuk dibuang sepenuhnya pada tahap ini.

Hasil akhirnya adalah `df_final` yang secara struktur hanya memuat kolom yang benar-benar dibutuhkan, dengan label yang sudah terstandarisasi, dan fitur yang sudah dalam format yang siap dikonsumsi model secara langsung.

	job_mapped	skills	work_type	keyword	company
0	Back End Developer	c#, css3, html5, python, sql	Remote	Back End Developer	Keyvoto
1	Back End Developer	docker, git, gitlab, hibernate, java, jenkins,...	On-site	Back End Developer	Müller's Solutions
2	Back End Developer	c++, foundation, github, java, netlify, vercel	On-site	Back End Developer	RXPART ADVISORS PRIVATE LIMITED
3	Back End Developer	docker, git, gitlab, google cloud platform (gc...	Remote	Back End Developer	Digital Waffle
4	Back End Developer	angular, computer vision, docker, git, javascr...	On-site	Back End Developer	Analyticsmart

BAB V


PENGEMBANGAN *DASHBOARD* BERBASIS STREAMLIT

Setelah seluruh proses analisis data dan pembangunan dataset final selesai, tahap berikutnya adalah mengemas seluruh hasil kerja tersebut ke dalam bentuk yang dapat diakses dan digunakan secara langsung oleh pengguna akhir. Untuk itu, dikembangkan dua *Dashboard* terpisah menggunakan Streamlit, masing-masing dengan tujuan dan audiens yang berbeda.

5.1. *Dashboard Analisis Pasar Kerja IT*

Dashboard pertama dirancang untuk menjawab kebutuhan pengguna yang ingin memahami kondisi pasar kerja IT secara keseluruhan berdasarkan data nyata dari LinkedIn. Seluruh visualisasi dan temuan dari keenam pertanyaan bisnis yang telah dijawab pada tahap *Explanatory Analysis* dikemas ulang ke dalam antarmuka interaktif yang dapat dieksplorasi tanpa perlu membuka notebook.

Pengguna dapat melihat distribusi *skill* paling banyak diminta, pola *work type* per kategori pekerjaan, perbandingan kompleksitas *skill* antar pekerjaan, *skill* penciri tiap kategori, hingga pola *co-occurrence skill* yang semuanya dalam satu tampilan yang dapat difilter dan disesuaikan secara dinamis. *Dashboard* ini ditujukan terutama bagi pencari kerja yang ingin memahami lanskap pasar sebelum menentukan arah pengembangan kariernya, maupun bagi institusi pendidikan yang ingin menyelaraskan kurikulum dengan kebutuhan industri. Untuk tampilan *streamlit* lebih detailnya ada pada gambar di bawah ini:







Terlihat *Dashboard* diatas sudah menunjukkan jawaban dari pertanyaan bisnis sesuai dengan analisis yang dilakukan.

5.2. *Dashboard Untuk Rekomendasi Skill*

Dashboard kedua adalah implementasi langsung dari model deep learning yang dihasilkan oleh tim *AI Engineer*. Pengguna cukup memasukkan nama pekerjaan yang dituju, dan sistem akan secara otomatis memberikan rekomendasi *skill* apa saja yang perlu dikuasai untuk posisi tersebut, diurutkan berdasarkan confidence score dari model.



Di balik layar, Input pengguna diproses melalui fungsi `map_to_keyword()` yang menggunakan TF-IDF character n-gram similarity untuk memetakan nama jabatan ke salah satu dari 105 keyword standar sebelum diteruskan ke model. Hal ini memastikan bahwa variasi penulisan seperti "*backend dev*" atau "*ML Engineer*" tetap menghasilkan rekomendasi yang akurat. Selain daftar *skill*, *Dashboard* ini juga menampilkan *career roadmap* yang dihasilkan secara generatif menggunakan Groq/LLaMA, memberikan narasi perjalanan belajar yang lebih personal dan kontekstual bagi pengguna. Untuk tampilan *Dashboard* rekomendasi *skill* dapat dilihat dibawah ini:



Terlihat dari hasil di atas, untuk nama pekerjaan computer vision dan data engineer sudah memberikan rekomendasi *skill* yang relevan.

5.3. Deploy Dashboard Via Streamlit

Kedua *Dashboard* di atas di *deploy* ke Streamlit Community Cloud agar dapat diakses secara publik tanpa instalasi apapun di sisi pengguna. Seluruh file yang dibutuhkan termasuk `app.py`, `requirements.txt`, artifact model dari notebook *AI Engineer*, serta `df_final.csv`, `tfidf_vec.pkl`, dan `keywords.pkl` dari notebook ini di-push ke satu repositori GitHub yang kemudian dihubungkan langsung ke Streamlit Cloud. Setelah *Deployment* berhasil, kedua *Dashboard* dapat diakses melalui URL publik yang diberikan oleh Streamlit Cloud dan siap digunakan oleh siapapun tanpa batasan platform maupun perangkat.



Secara berurutan, gambar di atas merupakan *repository* lengkap untuk *Dashboard* yang menampilkan jawaban dari *business question* serta *Dashboard* yang digunakan sebagai *platform* untuk melakukan prediksi *skill*.

BAB VI

KESIMPULAN DAN REKOMENDASI

6.1. Kesimpulan

Proyek ini berhasil menjawab seluruh pertanyaan bisnis yang dirumuskan di awal melalui analisis data lowongan kerja IT yang dikumpulkan dari LinkedIn Global. Berikut adalah temuan dari masing-masing pertanyaan bisnis:

Dari BQ1 ditemukan bahwa Python, SQL, Kubernetes, Docker, dan Terraform adalah *skill* yang paling banyak diminta secara global. Python sendiri muncul di sekitar 25% dari seluruh lowongan dalam dataset, menjadikannya bukan lagi sekadar keunggulan kompetitif melainkan sudah menjadi ekspektasi dasar di hampir semua pekerjaan IT.

Dari BQ2 ada pola yang cukup menarik tidak semua pekerjaan IT memiliki keterbukaan yang sama terhadap tipe kerja *remote*. Pekerjaan DevOps dan Cloud *Engineer* tercatat sebagai yang paling *remote-friendly*, sementara pekerjaan yang sifatnya lebih operasional seperti IT *Support* dan *Network Engineer* masih sangat dominan *on-site*. Ini mencerminkan bahwa fleksibilitas lokasi kerja sangat bergantung pada sifat pekerjaan itu sendiri, bukan semata-mata preferensi perusahaan.

Dari BQ3 ditemukan bahwa pekerjaan DevOps dan Cloud rata-rata mensyaratkan 7 hingga 8 *skill* per lowongan, jauh di atas pekerjaan IT Ops yang hanya 2 hingga 3 *skill*. Ini mengindikasikan bahwa semakin tinggi keterlibatan infrastruktur dalam sebuah pekerjaan, semakin luas cakupan *skill* yang dituntut dari kandidatnya.

Dari BQ4 ditemukan bahwa setiap kategori pekerjaan memiliki pola *skill* yang sangat khas dan tidak banyak tumpang tindih satu sama lain. Flutter *Developer* hampir eksklusif menggunakan Dart, ML *Engineer* sangat identik dengan PyTorch, dan *Cyber Security Analyst* dicirikan oleh penguasaan SIEM. Temuan ini menjadi landasan validasi bahwa model rekomendasi yang dibangun memang memiliki dasar yang cukup kuat dari sisi data.

Dari BQ5 ditemukan bahwa lowongan *Remote* secara rata-rata mensyaratkan 43% lebih banyak *skill* dibanding *On-site*, dan perbedaan ini terkonfirmasi secara statistik melalui A/B *Testing* dengan nilai p jauh di bawah 0.05. Artinya, kandidat yang ingin bekerja secara *remote* perlu mempersiapkan diri lebih serius dibanding yang menyasar posisi *on-site*.

Dari BQ6 ditemukan bahwa Python dan SQL adalah pasangan *skill* yang paling sering muncul bersama, diikuti oleh klaster Docker, Kubernetes, dan Terraform yang membentuk satu ekosistem yang kohesif di dunia DevOps. Pola *co-occurrence* ini mencerminkan bagaimana industri sesungguhnya menggunakan *skill* secara berkelompok, bukan secara terpisah-pisah.

6.2. Rekomendasi

Berdasarkan seluruh temuan di atas, berikut rekomendasi yang dapat diambil oleh masing-masing pihak:

1. Bagi pencari kerja dan mahasiswa, langkah paling efisien adalah memulai dari Python dan SQL karena keduanya relevan di hampir semua jalur karier IT. Setelah fondasi itu kuat, pilih satu klaster *skill* yang sesuai dengan tujuan karier kalau menuju Data, lanjutkan ke Spark dan dbt. Kalau menuju DevOps, lanjutkan ke Docker, Kubernetes, dan Terraform. Mempelajari *skill* dalam satu klaster secara berurutan jauh lebih efektif daripada mengambil *skill* acak dari berbagai bidang.
2. Bagi yang ingin bekerja *remote*, data menunjukkan bahwa jalur DevOps dan Cloud adalah pilihan paling realistis. Bukan hanya karena persentase *remote*-nya paling tinggi, tapi juga karena *skill* yang dituntutnya konkret dan terukur, artinya ada jalur belajar yang jelas untuk mencapainya.
3. Bagi institusi pendidikan dan pelatihan, temuan *co-occurrence* seharusnya menjadi acuan dalam menyusun kurikulum. Mengajarkan Python tanpa SQL, atau Docker tanpa Kubernetes, akan menghasilkan lulusan yang tidak sepenuhnya siap menghadapi ekspektasi industri yang nyata. Kurikulum yang disusun berdasarkan klaster *skill* akan jauh lebih relevan dibanding yang disusun berdasarkan *skill* individual.

LAMPIRAN

Lampiran 1. Link Github Untuk Dashboard EDA

https://github.com/Bax12299/Dashboard_Capstone_EDA

Lampiran 2. Link Github Untuk Dashboard EDA

https://github.com/Bax12299/Predict_Skill_Capstone

Lampiran 3. Link Untuk Mengakses Dataset

https://github.com/Bax12299/Dataset_Capstone